MACHINE LEARNING CANVAS

Designed for: MiBici, Guadalajara Designed by: Equipo 03, TC5061 Date: 18/10/2026 Iteration: 2

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

P1 Regresión. Estación × día: viajes que iniciarán mañana; se observa al cerrar el día.
P2 Clasificación. Estación × bloque de 3 h: en riesgo si |salidas − llegadas| ≥ 40 % de la capacidad en el siguiente bloque.
P3 Clustering. Estación: grupo según su patrón de uso.
Riesgo aproximado. Sin inventario, se usa el flujo neto: con la estación a la mitad, mover 40 % deja solo 10 % de margen.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

P1 Asignar bicicletas por zona y programar mantenimiento en los días de menor demanda.
P2 Ordenar las visitas del camión de rebalanceo en cada turno: primero las estaciones con mayor probabilidad de riesgo, hasta donde alcance su capacidad.
P3 Decidir dónde abrir o ampliar estaciones y qué grupos necesitan una operación propia.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiarios. Operador (P1), equipo de rebalanceo (P2) y planeación urbana (P3); al final, los usuarios, que encuentran bici y anclaje.
Problema. Hoy se reacciona cuando la estación ya está vacía o llena, sin pronóstico por estación.
Integración. Reporte diario de demanda, lista cada 3 h de estaciones en riesgo y mapa de grupos.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Ingesta reproducible (make data): descarga, normaliza, limpia y guarda en Parquet. Las etiquetas salen de los viajes.
Limpieza: duraciones negativas, < 2 min en la misma estación, > 12 h, duplicados y nacimientos antes de 1920.
Cada mes nuevo se agrega en config.py y se vuelve a correr; el manifiesto (filas y hash) versiona los datos.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Viajes. datos_abiertos_AAAA_MM.csv, oct 2025 a sep 2026: 4,332,379 viajes limpios.
Estaciones. nomenclatura_2026_09.csv: 484, con ubicación y capacidad; municipio por prefijo (GDL, ZPN, TLQ).
Límites. Sin inventario, rebalanceo ni clima. Usuario_Id se elimina; género y año de nacimiento solo agregados por estación.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

P1 MAE en viajes (ago y sep 2026) contra el baseline; se despliega solo si lo mejora.
P2 Falsa alarma = visita innecesaria; riesgo no detectado = usuario sin bici o anclaje. Average precision, más recall y precisión (umbral 0.5).
P3 Grupos interpretables, con mejor silueta que el municipio.
Equidad. Revisar el error por municipio.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Por lotes. P1 cada noche para el día siguiente. P2 cada 3 h con el bloque anterior. P3 cada trimestre o al abrir estaciones.
Supuesto: el portal publica cada mes; operar cada 3 h requiere datos del operador casi en tiempo real. Aquí se simula con los datos abiertos.
Corre en una laptop con pandas y scikit-learn.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Baseline y candidato por pregunta; entrena oct 2025 a jul 2026, prueba ago y sep.
Baselines. P1 mismo día de la semana anterior. P2 riesgo del mismo bloque la semana anterior. P3 municipio.
Candidatos. P1 y P2 HistGradientBoosting (P2 balanceado); P3 KMeans (k 3 a 8).
Reentreno mensual; 6 runs en MLflow.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

P1 Viajes de ayer y de hace 7 días, media de 7 días, día, festivo y capacidad.
P2 Flujo neto de los 2 bloques previos, salidas y llegadas previas, riesgo hace 1 semana, hora, día y capacidad.
P3 Salidas por hora, fin de semana, balance neto y volumen (solo entrenamiento); % de usuarias y edad mediana solo describen.
Sin información posterior al momento de predecir.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Modelo. Cada mes, MAE (P1) y average precision (P2) reales contra los de prueba. Si se degradan, se reentrena. P3: cambios de grupo al sumar meses o estaciones.
Negocio. Horas con estaciones vacías o llenas y viajes atendidos por día, revisados cada mes con el operador.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO